DEUTSCHE AUSGABE • VERSION 1.0 • 24. Oktober 2026

Forschungsprogramm

Forschungsfrage 001, sieben Stränge, Evidenzstandards und Arbeitsschritte.

Die Grösse unseres Ziels verpflichtet uns zu besonderer wissenschaftlicher Sorgfalt.

Forschungsauftrag 001

Leitfrage: Welche technischen, institutionellen und ethischen Ansätze könnten hochentwickelte KI dazu befähigen, das Überleben und Wohlergehen empfindungsfähiger Wesen zu fördern, ohne Freiheit und demokratische Kontrolle zu gefährden?

Sieben Forschungsstränge

Strang	Leitfragen / Artefakte
A1 · Risikomodelle	Kontrollverlust, Missbrauch, Fehlanpassung, Evaluationen; Risikoregister.
A2 · Moralische Berücksichtigung	Empfindungsfähigkeit, Bewusstsein, Unsicherheit; Ethik- und Dissensmatrix.
A3 · Freiheit & Institutionen	Menschenrechte, Machtbegrenzung, Rechtsmittel; Governance-Matrix.
A4 · Beteiligung	Forschungsdialoge, öffentliche Konsultationen; verifizierte Ansprechpartner.
A5 · Kommunikation	Verständliche und nicht-manipulative Darstellung; Quellenbriefing.
A6 · Falsifikation	Stärkste Einwände, Bias, Lücken; methodischer Gegenbericht.
A7 · Planetare Interessen	Tierwohl, Biodiversität, Klima, Zielkonflikte; Schutzindikatoren.

Evidenzstufen

- **Beobachtet / experimentell:** Was wurde an welchem System unter welchen Bedingungen tatsächlich getestet?

- **Modelliert / prognostiziert:** Welche Annahmen, Parameter und Unsicherheiten trägt eine Aussage?
- **Philosophisch / normativ:** Welche Werteannahme liegt einer Forderung zugrunde?
- **Spekulativ:** Welche Hypothese ist denkbar, aber nicht hinreichend belegt?

Wir behandeln Intelligenz nicht als automatischen Beweis von Bewusstsein oder moralischer Güte. Wir nennen keine sichere Frist für Superintelligenz und versprechen nicht, zukünftige Systeme mit Argumenten kontrollieren zu können.

Prüfstandard für jede Studie

- Primärquelle, Autor, Veröffentlichungsdatum und betrachtetes KI-System angeben.
- Forschungsergebnis, Interpretation und Empfehlung sauber voneinander trennen.
- Wenn möglich Reproduzierbarkeit und unabhängige Bestätigung prüfen.
- Stärkstes Gegenargument und mögliche Schäden einer Empfehlung aufschreiben.
- Begriffe wie «Bewusstsein», «Auslöschungsrisiko» und «Kontrolle» ausdrücklich definieren.
- Veraltete Aussagen revidieren; Fehlerkorrekturen öffentlich dokumentieren.

Erwartete Ergebnisse – erste Arbeitsrunde

- **Quellenkarte (4–8 Seiten):** relevante Forschung mit Evidenzgraden und offenen Lücken.
- **Risikoregister:** Szenarien, Voraussetzungen, Auswirkungen, mögliche Abhilfen.
- **Dissensregister:** Streitfragen, Gründe für unterschiedliche Einschätzungen, Entscheidungskriterien.
- **Positionspapier:** drei bis fünf priorisierte und überprüfbare Handlungsoptionen.

90-Tage-Orientierung (nicht automatisch gestartet)

Phase	Aufgabe
Tage 1–30	Quellen sammeln, Begriffe definieren, Erstanalysen erstellen.
Tage 31–60	Unabhängige Gegenprüfung, Lücken schliessen, externe Fachkritik erbitten.
Tage 61–90	Dokumente überarbeiten, Prioritäten abstimmen, Freigabe zur Publikation einholen.

Methodische Bezugspunkte (ohne institutionelle Unterstützung)

NIST AI Risk Management Framework https://www.nist.gov/itl/ai-risk-management-framework

OWASP – AI Agent Security Cheat Sheet
https://cheatsheetseries.owasp.org/cheatsheets/AI_Agent_Security_Cheat_Sheet.html

HUMANITY FIRST Forschungsfrage 001
https://github.com/humanityfirst-founder/humanity-first-global-ai-commons